

MCTS exploration enhanced A^* Search

2022111931
이정진

Table of Contents

역합성 분석

- 목표
- 용어 정리
- 역합성 분석 진행 과정

기존 역합성 분석 모델

- A* search
- Monte Carlo Tree Search
- USPTO benchmark

MEEA*

- MEEA*
- MEEA*-PC

Experiment

- Variable
- Environment
- Experiment Result


Conclusion

- Contribution
- Remaining task

1. 역합성 분석

역합성 분석의 목표

역합성 분석(retrosynthetic analysis)은 목표 분자(target molecule)를 상업적으로 이용 가능한 building blocks로 분해하여 합성 경로를 찾는 것이다.



1. 역합성 분석

핵심 용어 (화학/합성)

Target molecule

합성하고자 하는 최종 분자

Precursors (Reactants)

목표 분자를 합성할 수 있는 전구체 집합

Building blocks


합성의 종착점으로 삼는 상업적 출발 물질

Synthetic route

목표 분자를 출발 물질로 만드는 전체 반응 경로

Single-step model ($\mathcal{B}$)

목표 분자를 가능한 전구체(reactants)로 분해하는 **한 번의 화학 반응**을 예측하는 모델.



1. 역합성 분석

탐색 용어

State ($s, \mathcal{S}$)

합성해야 할 분자들의 집합

Action ($a, \mathcal{A}$)

특정 분자에 적용 가능한 반응


Transition Model ($\mathcal{T}$)

반응 a 를 상태 s 에 적용해 새로운 분자 집합을 생성

Cost ($\mathcal{C}$)

합성의 누적 비용 또는 난이도. 낮을수록 유리함.

(b)



1. 역합성 분석

역합성 분석의 진행 과정

1. 목표 분자(m_0) 입력
2. Single-step model을 통한 가능한 전구체 후보군 생성
- 3. 탐색 알고리즘을 통한 확장할 노드 후보군 생성**
4. Guiding function을 통해 확장 우선순위 결정
5. 모든 분자가 building blocks라면 retrosynthetic 종료

2. 기존 역합성 분석 모델

A* search

$$f(x) = g(x) + h(x)$$

- g : 지금까지의 누적 반응 비용
- h : cost estimate function이 예측한 남은 비용 (*heuristic*)
- 현재까지 A* search를 바탕으로 한 모델은 $h(x)$ 의 정확도를 개선시키는 방향으로 발전함.
 - Retro*은 1 fully connected layer 모델로 $h(x)$ 를 예측
 - Retro*+는 기존 Retro*의 cost estimator의 학습 기법을 발전

2. 기존 역합성 분석 모델

A* search (장점)

(b) Success rate on USPTO benchmark.




Fig. 4(b) one-step model을 많이 호출하면 Retro++의 정확도가 1에 수렴한다.

- **Admissibility**와 **Consistency**를 만족하고 리소스가 제한적이지 않다면 **최적해가 보장된다**.

2. 기존 역합성 분석 모델

A* search (단점)




Fig. 2(a) non-optimal branch의 깊은 탐색으로 인해 optimal branch의 탐색이 부족하다.

- heuristic function인 cost estimate function에 대한 의존도가 높다.

2. 기존 역합성 분석 모델

Monte Carlo Tree search (MCTS)

- Search Tree 구조에 Monte Carlo를 사용
- 핵심 절차
 1. **Selection**: 확장할 노드 선택 (tree policy: UCT, **pUCT**)
 - ✓ **exploitation**과 **exploration** 간의 균형
 2. **Expansion**: 선택한 노드의 자식 노드 추가
 3. **Simulation**: 새 노드에서 rollout
 4. **Backpropagation**: rollout 결과를 루트까지 전달

2. 기존 역합성 분석 모델

Monte Carlo Tree search (장점)

Table 3 | The results by imposing a time limits of 10 min on every run on USPTO benchmark

	Retro ⁺	A* ($K_{MCTS} \rightarrow \infty$)	MCTS ($K_{MCTS} = 1$)	MEEA [*]
Success rate	96.84%	99.47%	97.37%	100.0%
First solution time	43.67 s	22.99 s	55.33 s	19.93 s
Number of clusters	^a	4.09	4.26	4.17
TED	11.10	10.15	11.27	10.94
Leaves overlap	0.606	0.638	0.582	0.605

^aRetro⁺ is not designed to generate multiple synthetic pathways, and only the best route is provided. The number of clusters for Retro⁺ is not presented in the table.

- exploration을 통한 **route diversity**
- PaRoutes 테스트
 - A* 방식과 비교했을 때 **route quality**와 **diversity** 면에서 더욱 우수
 - 10 steps 이상의 case들은 제외하면서 MCTS에게 유리하게 작용

2. 기존 역합성 분석 모델

Monte Carlo Tree search (단점)






Fig. 2(b) non-optimal branch의 탐색으로 인해 optimal branch의 깊은 탐색이 부족하다.

- exploration으로 인한 **non-optimal branch** 탐색
- **compulsive exploration**은 깊은 탐색을 방해한다.

2. 기존 역합성 분석 모델

USPTO benchmark



- Retro*+의 경우, 실패한 전체 테스트 중 78.95%는 7단계 이내에 합성될 수 있으며, 89.47%는 9단계 이내에 합성될 수 있다.
- MCTS의 경우, 실패한 전체 테스트 중 45%는 8단계 이상의 반응을 요구, 8단계 이상의 반응을 요구하는 분자들 중 84.8% 합성 경로를 예측하는데 실패했다.

3. MEEA*

Idea

MCTS 기반의 **exploration(pUCT)**적인 성질은 유지하되 **A* algorithm**의 방식을 차용하여 **Selection**을 진행하자.

- 핵심 절차
 1. **Simulation**: f -value 를 구할 candidate set을 추출하고 실제 f -value를 구한다.
 2. **Selection**: 가장 낮은 f -value를 가진 child node에게 priority를 부여한다.
 3. **Expansion**: 선택한 노드의 자식 노드 추가

3. MEEA*

MEEA* Process (Simulation)

1. Single-step model($\mathcal{B}$)을 통해 목표 분자의 전구체들의 집합들을 찾는다.
2. MCTS의 **tree policy(pUCT)**를 통해 f -value를 구할 candidate set을 산출

$$a^* = \operatorname{argmax}_{a \in \mathcal{A}} \left\{ -Q(s, a) + c_{puct} \frac{1}{|\mathcal{A}|} \frac{\sqrt{\sum_{b \in \mathcal{A}} N(s, b)}}{1 + N(s, a)} \right\}$$

- $Q(s, a)$: f -value의 경험적 추정치 (**exploitation**)
- c_{puct} : **탐험(exploration)**의 강도를 조정하는 hyperparameter
- $\mathcal{A}$: 취할 수 있는 action 집합 (**uniform distribution**)
- $N(s, a)$: 상태 s 일 때, a 라는 행동을 선택한 횟수
- $\sum_{b \in \mathcal{A}} N(s, b)$: 특정 상태에서 가능한 모든 행동들이 선택된 횟수

3. MEEA*

MEEA-PC

MEEA* 모델은 **cost estimator**와 **Single-step retrosynthesis model**에 의존한다.

(a) Learning curve of cost estimator in Retro*.




Fig. 4(a) Retro* estimator function의
overfitting

$$\begin{aligned} h(s) &= h(m_i, m_j, \dots)h(s) \\ &= \sum_{m \in s} h(m) \end{aligned}$$

3. MEEA*

MEEA-PC

$$\mathcal{L}(\theta) = \mathcal{L}_{RL}(\theta) + \lambda \mathcal{L}_{PC}(\theta)$$

$$\mathcal{L}_{RL}(S) = (h(s) - c(s))^2$$

$$\mathcal{L}_{PC} = \left(f(s) - \bar{f}(s)\right)^2, \bar{f}(s) = \frac{1}{N+1} \sum_{i=0}^N f(s_i)$$

$$c(s) = \log p_r(a|m)$$

L_{RL} : cost estimator와 single-step model 간의 loss

L_{PC} : f -value의 consistency loss

λ : 두 loss 간의 가중치 parameter

$c(s)$: single-step model을 policy로 했을 때 a 라는

행동을 선택했을 때 cost

Bias-Variance Decomposition에 따라 $\left(f(s) - \bar{f}(s)\right)^2$ 값이 작을 수록 정규화가 된다.

4. 실험

실험 변수와 평가 지표

통제 변수

- 데이터셋
- Singel-step model (Retro*+ policy or BioNavi-NP policy)
- 평가 지표

독립 변수

- 탐색 알고리즘 (Retro*+, MCTS, MEEA*)
- K_{MCTS} value
- MEEA*-PC의 λ
- Policy 종류 (Retro*+ policy vs BioNavi-NP policy)

4. 실험

실험 결과 (USPTO benchmark)

Table 1 | Performance summary on USPTO benchmark with a hard time limit of 500 single-step model calls, or 10 min

Algorithm	Success rate	Avg length	Avg cost	Avg time
Exhaustive search	100.0%	6.67	10.66	—
Retro ^{*30}	86.84%	9.71	15.33	157.11
Retro ^{*-0} ³⁰	79.47%	11.21	19.40	208.09
Retro ^{*+} ³¹	91.05%	8.74	15.23	100.15
Retro ^{*+-0} ³¹	96.32%	7.69	11.66	96.22
RetroGraph ³³	99.47%	6.33	12.92	45.13
MCTS ^{a25}	33.68%	>21.22	>44.91	370.51
MCTS ⁺ ^{a25}	35.79%	>20.55	>43.48	365.21
GRASP ²⁷	98.94%	6.17	13.91	48.47
MEEA [*]	100.0%	6.11	9.88	55.72

Molecules that fail to synthesize are assigned a large synthetic length and cost. The minimum average length and cost are calculated by setting the length and cost of successfully synthesized molecules to 0.

Values marked with bold are the best performance under each metric.

^aThe success rates of MCTS and MCTS+ are borrowed from³⁰.

4. 실험

실험 결과 (10개의 데이터셋)

Table 2 | The success rate comparison tested in 10 datasets

Dataset	Retro ^{*30}	Retro ^{*+31}	EG-MCTS ²⁶	MEEA [*]	MEEA [*] -PC
USPTO ³⁰	86.84%	91.05%	96.84%	100.0%	94.74%
logS ⁴⁴	67.08%	69.29%	71.74%	73.22%	80.34%
BBBP ⁴⁸	47.87%	52.46%	54.92%	57.70%	66.88%
ClinTox ⁵²	38.69%	43.15%	45.54%	50.00%	60.51%
logP ⁴⁵	53.96%	61.14%	62.72%	65.24%	73.72%
DPP4 ⁴⁹	68.52%	78.59%	77.05%	83.63%	96.04%
BACE ⁵⁰	33.71%	38.35%	40.07%	40.15%	56.32%
Ames ⁴⁷	57.40%	63.51%	66.61%	68.29%	78.74%
Toxicity LD50 ⁴⁶	55.39%	59.98%	64.22%	66.28%	72.94%
SVS ⁵¹	50.14%	55.93%	58.23%	60.19%	73.01%
Total	54.18%	60.50%	62.20%	65.14%	76.27%

Values marked with bold are the best performance under each metric.

4. 실험

실험 결과 (자연산물 NP)

- BioNavi-NP 단독: 90.2%.
- MEEA*-PC + BioNavi-NP policy: 97.68%.

4. 실험

실험 결과 (K_{MCTS})

Table 3 | The results by imposing a time limits of 10 min on every run on USPTO benchmark

	Retro⁺	$A^*(K_{MCTS} \rightarrow \infty)$	MCTS($K_{MCTS} = 1$)	MEEA[*]
Success rate	96.84%	99.47%	97.37%	100.0%
First solution time	43.67 s	22.99 s	55.33 s	19.93 s
Number of clusters	^a	4.09	4.26	4.17
TED	11.10	10.15	11.27	10.94
Leaves overlap	0.606	0.638	0.582	0.605

^aRetro⁺ is not designed to generate multiple synthetic pathways, and only the best route is provided. The number of clusters for Retro⁺ is not presented in the table.

5. Conclusion

Contribution

- A*와 MCTS의 장점 결합 → 효율성과 다양성 동시 달성.
- Path Consistency로 guiding function 개선.
- USPTO, QSAR, NP dataset에서 모두 우수한 성능 입증.

5. Conclusion

Remaining task

- Single-step model 정확도 개선 필요.
- K_{MCTS} 최적값 자동 조정.
- 대규모 분자/복잡 합성에서의 확장성.

Thank You!